

Netflix Stock Price Prediction

Hikmet Terzioğlu

Bilgisayar Mühendisliği Bölümü
TOBB Ekonomi ve Teknoloji Üniversitesi
Söğütözü, Ankara /Türkiye
hterzioglu@etu.edu.tr

Video linki: <https://youtu.be/UWFEHdyKZYU>

Bu çalışma, finansal verilerin zaman içindeki değişimlerini analiz etmek için çeşitli makine öğrenimi tekniklerinin nasıl kullanılabileceğini araştırmaktadır. Geleneksel regresyon ve ARIMA modellerinin yanı sıra, derin öğrenme yöntemlerinden olan RNN ve LSTM modelleri de incelenmiştir. Veri seti olarak NFLX hisse senedi fiyatları kullanılmıştır. Makalenin amacı, bu farklı yöntemlerin finansal veri analizindeki etkinliğini karşılaştırmaktır. Geleneksel ve derin öğrenme modelleri, veri setinin zaman içindeki değişen dinamiklerini yakalama yetenekleri bakımından değerlendirilmiştir. Bulgular, RNN ve LSTM gibi derin öğrenme modellerinin geleneksel yöntemlere kıyasla daha yüksek tahmin doğruluğu sağlayabileceğini göstermektedir. Sonuç olarak, finansal veri analizinde derin öğrenme tekniklerinin kullanımının artan önemi vurgulanmaktadır. Bu çalışmanın bulguları, yatırımcıların ve analistlerin daha iyi tahminlerde bulunmalarına yardımcı olabilecek potansiyel faydalar sunmaktadır. Anahtar Kelimeler: Finansal Veri Analizi, Makine Öğrenimi, Derin Öğrenme, RNN, LSTM.

I. INTRODUCTION

Finansal piyasaların dinamik yapısı, yatırımcıların ve analistlerin varlık fiyatlarının gelecekteki hareketlerini tahmin etmelerini zorlaştıran karmaşıklıklarla doludur. Bu bağlamda, hisse senedi fiyatlarının tahminlenmesi, yatırım kararları ve portföy yönetimi için kritik öneme sahiptir. Hisse senetleri, ekonomik ve finansal olaylara duyarlıdır ve bu nedenle fiyatlarında ani değişiklikler meydana gelebilir.

Bu çalışma, Netflix (NFLX) hisse senedinin gelecekteki kapanış fiyatlarını tahmin etmek için çeşitli yöntemlerin uygulanmasını ele almaktadır. Netflix gibi büyük teknoloji şirketlerinin hisse senetleri, genellikle piyasa trendlerini ve yatırımcıların algılarını yansıtan önemli varlıklardır. Bu nedenle, bu çalışma, hisse senedi fiyat tahmini konusundaki yöntemlerin etkinliğini değerlendirmeyi amaçlamaktadır.

Çalışmanın temel amacı, farklı veri analizi ve tahmin yöntemlerini kullanarak Netflix hisse senedinin kapanış fiyatlarını ayrıntılı bir şekilde incelemektir. Bu amaç doğrultusunda, öncelikle veri setinin kapsamlı bir tanıtımı yapılmış ve daha sonra verinin görsel ve istatistiksel analizi gerçekleştirilmiştir. Geleneksel bir yaklaşım olarak Lineer Regresyon modeli kullanılarak tahminlemeler yapılmış ve modelin performansı kritik bir bakış açısıyla değerlendirilmiştir.

Ayrıca, bu çalışma, ARIMA (Oto-Regressif Entegre Hareketli Ortalama) modeli ile hisse senedi fiyatlarına ilişkin tahminler elde etmeyi de hedeflemektedir. ARIMA modeli, zaman serisi

verilerini analiz etmek ve gelecekteki değerleri tahmin etmek için yaygın olarak kullanılan bir yöntemdir. Modelin başarısı, tahminlerin güvenilirliği ve istikrarı açısından titizlikle değerlendirilmiştir.

Bununla birlikte, bu çalışmanın odak noktası, derin öğrenme tekniklerinden olan RNN (Rekürrent Sinir Ağı) ve LSTM (Uzun Kısa Süreli Bellek) modellerini de içermektedir. RNN ve LSTM gibi modeller, zaman içindeki ilişkileri ve bağımlılıkları modelleme yetenekleriyle öne çıkar ve bu nedenle zaman serisi verilerinin analizi için tercih edilir. Bu modellerin kullanımıyla elde edilen tahmin sonuçları, kapsamlı bir şekilde sunularak detaylı bir analiz sunulmuştur.

Çalışmanın geri kalan kısmında, Lineer Regresyon, ARIMA, RNN ve LSTM modellerinin sonuçları karşılaştırılmış ve tahminlerin etkinliği ayrıntılı bir şekilde değerlendirilmiştir. Ayrıca, gelecekteki 30 günlük dönem için Netflix hisse senedi kapanış fiyatlarının tahmini sunulmuştur. Bu tahminlerin gerçek değerlerle karşılaştırılması, modellerin gerçek dünya verilerine ne kadar iyi uyum sağladığını belirlemek için yapılmıştır.

Sonuç olarak, bu çalışma farklı veri analizi ve tahmin yöntemlerini kullanarak hisse senedi fiyat tahminlerini kapsamlı bir şekilde incelemeyi amaçlamaktadır. Elde edilen sonuçlar, yatırımcıların ve analistlerin farklı piyasa koşullarında hisse senedi fiyatlarını tahmin etmek için kullanabilecekleri çeşitli yaklaşımlar hakkında geniş bir perspektif sunabilir. Bu çalışma, finansal analizde çeşitli tahmin yöntemlerinin karşılaştırılmasıyla ilgilenen araştırmacılar için önemli bir kaynak olabilir.

II. DATA PREPROCESSING AND EXPLORATION

A. Veri Kümesi Yükleme ve Açıklama

Veri Kaynağı ve Edinimi

Analizimizin ilk aşamasında, Netflix (NFLX) için geçmiş hisse senedi fiyatı verilerini içeren veri kümesini yüklemek gibi çok önemli bir görevi üstlendik. Bu veri kümesi, tüm analizimiz ve sonraki içgörülerimiz için temel temel görevi görür. Verilerin doğruluğunu ve güvenilirliğini sağlamak için veri kümesini, yüksek kaliteli veri akışlarıyla tanınan saygın ve köklü bir finansal veri sağlayıcısından temin ettik.

Veri Kümesinin Öznitelikleri

Yüklenen veri kümesi, hisse senedi fiyatı verilerinin çeşitli boyutlarını yakalayan kapsamlı bir öznitelik kümesi içerir. Bu özellikler, borsadaki eğilimleri, kalıpları ve davranışları

çözmede önemli bir rol oynar. Veri kümesinde yer alan temel nitelikler aşağıdaki gibidir:

Date: Hisse senedi fiyat bilgilerinin karşılık geldiği belirli işlem tarihlerini gösteren verilerin zamansal yönü.

Open Price: Bu özellik, NFLX hissesinin belirli bir işlem gününde işlem görmeye başladığı fiyatı belirtir. İlk piyasa duyarlılığı hakkında fikir verir.

High Price: Yüksek fiyat, NFLX hissesinin günün işlem saatlerinde ulaştığı en yüksek işlem değerini belirtir. Hisse senedinin en yüksek performansına bir bakış sunuyor.

Low Price: İşlem günü boyunca NFLX hisse senedinin ulaştığı en düşük işlem değerini temsil eden düşük fiyat, hisse senedinin minimum performans eşğine ilişkin bilgiler sunar.

Closing Price: Kapanış fiyatı, işlem gününün sonunda NFLX hissesinin nihai işlem değerini yansıtır. Günlük piyasa duyarlılığını değerlendirmek için kilit bir özelliktir.

Adj Close: Bu özellik, hisse senedinin değerinin zaman içinde daha doğru bir şekilde temsil edilmesini sağlamak için temettüler, hisse senedi bölünmeleri ve diğer düzeltmeler gibi kurumsal eylemleri etkiler.

Volume: İşlem günü boyunca işlem gören toplam NFLX hisse sayısını ifade eden bu özellik, piyasa katılımı ve likidite düzeyi hakkında fikir verir..




Fig. 1 :NFLX hisse senedi kapanış fiyatlarının dağılımını inceleyen bir grafik
B.İlk Veri Keşfi

Analize girmeden önce, veri kümesi hakkında kapsamlı bir anlayış kazanmak esastır. Verilerin yapısını ve özelliklerini belirlemek için ilk veri araştırması yapılmıştır. Veri kümesi, Python'da güçlü bir veri işleme kütüphanesi olan Pandas Veri çerçevesine yüklendi.

Veri Dağılımı Görselleştirme

Verilerin dağılımını görselleştirmek için çeşitli görselleştirme teknikleri kullandık. Bu değişkenlerin frekans dağılımını gösteren Açık, Yüksek, Düşük, Kapalı ve Hacim gibi özellikler için histogramlar oluşturuldu. Histogramlar, verilerde bulunan çarpıklığı veya aykırı değerleri belirlememize izin verdi.

Eksik Değerleri Kontrol Etme

Veri kalitesinin kritik bir yönü, eksik değerlerin belirlenmesi ve işlenmesidir. Tüm özniteliklerdeki eksik girdileri tespit etmek için veri kümesini kapsamlı bir şekilde inceledik. Eksik değerler analizimizin ve modellerimizin doğruluğunu potansiyel olarak etkileyebileceğinden bu adım çok önemliydi. Özet istatistiklerin hesaplanması, veri araştırmasında bir başka temel adımdır. Açık, Yüksek, Düşük, Yakın, Adj Yakın ve Hacim gibi sayısal özellikler için ortalama, medyan, standart sapma ve yüzdelikler gibi temel istatistiksel ölçümleri hesaplandı. Bu istatistikler, verilerin merkezi eğilimi, yayılması ve dağılımı hakkında fikir verdi.

C. Veri Temizleme

İlk araştırmadan sonra, analiz boyunca veri kümelerinin bütünlüğünü ve güvenilirliğini sağlamak için veri temizliğine devam edildi. İlk araştırma sırasında herhangi bir eksik değer tespit edilirse, bunları ele almak için uygun stratejiler kullanıldı. Yaygın teknikler arasında, ortalama veya medyan kullanılarak eksik değerlerin girilmesi veya önemsiz sayılırlarsa eksik değerlere sahip satırların kaldırılması yer alır.

D. Sonuç

"Veri Ön İşleme ve Keşif" aşaması, veri kümesinin iyi anlaşılmasını, tutarlı olmasını ve herhangi bir kritik sorundan yoksun olmasını sağlayarak analizimizin temelini attı. Görselleştirme yoluyla hisse senedi fiyat özelliklerinin dağılımı hakkında fikir edindik, eksik değerleri belirlendi ve özet istatistikler gerçekleştirildi. Sonraki veri temizleme adımları, veri kümelerinin kalitesini artırmaya yardımcı olarak daha gelişmiş analiz tekniklerine zemin hazırladı.

III. EXPLORATORY DATA VISUALIZATION

Netflix (NFLX) hisse senedi fiyatı veri kümesinin araştırılması, Matplotlib, Seaborn ve Plotly gibi önde gelen kütüphaneler tarafından kolaylaştırılan kapsamlı bir görselleştirme teknikleri paketini içeriyordu. Bu görselleştirmeler, NFLX hisse senedi fiyatlarının sergilediği zamansal eğilimler ve kalıplar hakkında değerli bilgiler sağlayarak fiyat değişimlerine, işlem hacmi dinamiklerine ve dağıtım özelliklerine ışık tuttu.

A.Fiyat Eğilimleri için Çizgi Grafikleri

Görsel olarak bilgilendirici çizgi grafikleri oluşturmak için Matplotlib ve Seaborn'un gücünden yararlanıldı. Bu grafikler, açılış, kapanış, yüksek ve düşük fiyatlar dahil olmak üzere kilit hisse senedi fiyatı özelliklerinin zamansal evrimini tasvir ediyordu. Bu fiyat özelliklerini zaman içinde temsil ederek, piyasa dinamiklerini gösterebilecek fark edilebilir eğilimleri, anormallikleri ve potansiyel korelasyonları ayırt etmeyi amaçlandı. Bu tür çizgi grafikleri, izleyicilerin hisse senedinin geçmiş performansını ve oynaklığını sezgisel olarak kavramasını sağladı.




Fig. 2 : hisse senedi kapanış fiyatlarını görselleştirmek için bir çizgi grafiği

B.İşlem Hacmi için Çubuk Grafikler

Ticaret faaliyetindeki kalıpları çözmek için ekip, Matplotlib kullanılarak oluşturulan çubuk grafikler kullandı. Bu grafikler, NFLX hisselerinin işlem hacmini farklı zaman aralıklarında etkin bir şekilde görselleştirdi. Her çubuğun yüksekliği doğrudan işlem hacmine karşılık geldi ve farklı dönemlerdeki işlem yoğunluğunun basit bir karşılaştırmasını sundu. Bu görsel temsil, alım satım faaliyetlerindeki ani artışları belirlemek için değerli bir araç olarak hizmet etti ve potansiyel olarak önemli piyasa olaylarına işaret etti.

C.Dağılım Analizi için Histogramlar

Dağılım analizi için temel bir araç olan histogramlar Matplotlib ve Seaborn kullanılarak hazırlandı. Histogramlar, kapanış fiyatları veya işlem hacmi gibi hisse senedi fiyat özelliklerinin sıklık dağılımının kapsamlı bir görünümünü sağladı. Verileri ayrı bölmelere bölerek ve her bölme düşen değerlerin sıklığını sergileyerek, bu histogramlar veriler içindeki merkezi eğilimleri ve dağılımları etkili bir şekilde aydınlattı. Bu, potansiyel aykırı değerleri belirlenmesini ve hisse senedi fiyat verilerinin genel dağıtım özelliklerini ölçmesini sağladı.

D.İçgörüler ve Gözlemler

Düzenlenen görselleştirmeler aracılığıyla birkaç önemli içgörü elde edildi. Örneğin, fiyat trendlerini çizgi grafikler aracılığıyla gözlemlemek, potansiyel olarak şirkete özgü duyurularla veya daha geniş piyasa trendleriyle bağlantılı olarak hisse senedi fiyatlarında hızlı artış veya düşüş dönemlerini ortaya çıkardı. İşlem hacmini vurgulayan çubuk grafikler, belirli dönemlerde artan faaliyete işaret ederek altta yatan nedenler hakkında daha fazla araştırma yapılmasını sağladı. Dağılım özelliklerini gösteren histogramlar, fiyat aykırı değerleri veya anormal işlem hacmi gibi anormalliklerin tanımlanmasını kolaylaştırdı.

E.Karar Verme Odaklı Görselleştirmeler

Keşif aşamasında düzenlenen görselleştirmeler, veriye dayalı karar vermenin temelini attı. Bu görsel temsiller sayısal verileri aşarak paydaşlara karmaşık piyasa dinamiklerinin bir bakışta kavranabileceği bir ortam sundu. Ayrıca, bu görsel içgörüler analiz, model formülasyonu ve stratejik planlamanın

sonraki aşamalarına rehberlik ederek, keşif görselleştirmesinin analitik süreçteki önemli rolünü vurguladı.

Özet olarak, çizgi grafikleri, çubuk grafikleri ve histogramları kapsayan çeşitli görselleştirmeler dizisi, Netflix hisse senedi fiyat verilerinin çok yönlü boyutlarının çözülmesine tutarlı bir şekilde katkıda bulundu. Bu görselleştirme odaklı keşif, daha derin analiz, modelleme ve nihayetinde altta yatan piyasa güçlerinin daha bilinçli bir şekilde anlaşılması için zemin hazırladı.

IV. STATISTICAL ANALYSIS

Netflix (NFLX) hisse senedi veri kümesinin incelenmesi, hisse senedinin kapanış fiyatlarına odaklanan kapsamlı bir istatistiksel analize genişletildi. Bu analiz, bir dizi temel istatistiksel önlem, dağılım görselleştirmesini ve sonraki modelleme için verilerin hazırlanmasını kapsıyordu.

Soruşturma, kapanış fiyatlarının merkezi eğilimlerini ve yayılmasını kısaca özetleyen temel istatistiksel önlemlerin hesaplanmasıyla başladı. Ortalama, medyan ve mod gibi ölçümler, veri kümesindeki tipik ve en sık meydana gelen değerler hakkında fikir vermek için hesaplandı. Bu önlemler, genel fiyat seviyesinin ve kapanış fiyatlarındaki potansiyel çarpıklığın hızlı bir şekilde anlaşılmasında paha biçilmezdi.

Kapanış fiyatlarının dağılımını daha derinlemesine incelemek için titizlikle bir histogram oluşturuldu. Verileri farklı kutulara bölen grafiksel bir temsil olan histogram, her bir kutu aralığına düşen kapanış fiyatlarının sıklığını sergiledi. Bu görselleştirme, verilerin normal, çarpık veya iki modlu bir dağılımı takip edip etmediğini ortaya çıkararak dağılımın şeklinin sezgisel bir tasvirini sağladı. Dağılımı anlamak, daha sonra uygun modelleme tekniklerini seçmek ve olası fiyat sonuçlarının aralığını anlamak için gerekiyordu.

Sonraki modelleme çabalarına hazırlık olarak, veri kümesi eğitim ve test alt kümelerine bölünmüştür. Bu bölünme, veri bölünmelerinde zamansal bağımlılıkların ve eğilimlerin korunmasını sağlamak için yürütüldü. Verilerin önemli bir bölümünü oluşturan eğitim alt kümesi model eğitimi için belirlenirken, test alt kümesi kaldı ve model değerlendirmesi için ayrıldı. Bu adım, modelin gerçek dünyadaki öngörücü performansını ölçmede ve görünmeyen verilere genellemede çok önemliydi. Kapanış fiyatlarının istatistiksel analizi, birkaç önemli içgörü sağlamıştır. Hesaplanan ortalama, medyan ve mod, dağıtımın merkezi eğilimlerinin kapsamlı bir görünümünü sağlayarak tipik kapanış fiyatı değerini ve varyasyonlarını ölçmeye yardımcı oldu. Öte yandan histogram, kapanış fiyatı dağılımının şeklinin görsel bir temsilini sunarak olası anormallikleri veya çarpık kalıpları vurguladı. Son olarak, eğitim-test verilerinin bölünmesi, modelin performansı üzerinde sağlam ve tarafsız bir değerlendirme yapılabilmesini sağlayarak sonraki model geliştirmeye zemin hazırladı. İstatistiksel analizden elde edilen içgörüler, bilinçli karar verme için temel bir katman oluşturdu. Bu istatistiksel özetler ve görselleştirmeler, kapanış fiyatı

verilerinin yalnızca ham rakamlardan hemen belli olmayabilecek temel özelliklerini açıkladı. Sonraki modelleme adımları ve stratejik düşünceler, istatistiksel bulgulardan doğal olarak etkilenecek, istatistiksel analizin finansal verilerin potansiyelini anlama ve bunlardan yararlanmadaki kritik rolünü güçlendirdi.

Sonuç olarak, Netflix'in kapanış fiyatlarının istatistiksel analizi, verilerin merkezi eğilimleri, dağıtım özellikleri hakkında kapsamlı bir anlayış sağladı ve sonraki modelleme çabalarının yolunu açtı. Bu analiz, ham veriler ile eyleme geçirilebilir içgörüler arasındaki boşluğu kapatarak analitik sürecin gidişatını şekillendirdi.

LINEAR REGRESSION MODEL

Netflix hisse senedi fiyatlarını Açık, Yüksek, Düşük ve Hacim gibi özelliklere göre tahmin etmek için doğrusal bir regresyon modeli uygulandı. Model, eğitim verileri üzerinde eğitilmiş ve test verileri üzerinde değerlendirilmiştir. Ortalama Kare Hatası (MSE), Kök Ortalama Kare Hatası (RMSE), Ortalama Mutlak Hata (MAE), Ortalama Mutlak Yüzde Hatası (MAPE) ve R-kare (R2) dahil olmak üzere performans ölçümleri hesaplandı.




Fig. 3 bir regresyon modelinin tahminlerini değerlendirmek için gerçek ve tahmini değerler arasındaki ilişkiyi gösteren bir grafik .

ARIMA TIME SERIES FORECASTING

Netflix hisse senedi fiyatlarının zaman serisi tahmini için Otoregresif Entegre Hareketli Ortalama (ARIMA) modelini kullanıldı. Model, yineleme yoluyla en uygun parametreler (p, d, q) bulunarak ayarlandı. ARIMA modeli önümüzdeki 30 gün için bir tahmin oluşturmak için kullanıldı ve tahmin edilen değerler gerçek verilerle birlikte çizildi.




Fig. 4: ARIMA tahmin sonucunu çizme

LONG SHORT-TERM MEMORY (LSTM) MODEL

Daha gelişmiş teknikler kullanarak Netflix hisse senedi fiyatlarını tahmin etmek için Uzun Kısa Süreli Bellek (LSTM) modeli uygulandı. Model, doğrusal regresyon modeliyle aynı özellikler kullanılarak eğitildi, ancak zaman içindeki karmaşık kalıpları ve bağımlılıkları yakalamak için verilerin zamansal doğasını kullandı.

LSTM modelini eğitim verileri üzerinde eğittikten sonra test verileri üzerindeki performansını değerlendirildi. Ortalama Kare Hatası (MSE), Kök Ortalama Kare Hatası (RMSE), Ortalama Mutlak Hata (MAE), Ortalama Mutlak Yüzde Hatası (MAPE) ve R-kare (R2) dahil olmak üzere doğrusal regresyon modelindeki benzer performans ölçümleri hesaplandı. Sonuçlar, lstm'nin daha karmaşık kalıpları yakalama yeteneğinin etkinliğini değerlendirmek için doğrusal regresyon modelinkilerle karşılaştırıldı.




Fig. 5 :Zaman serisi üzerinde gerçek hisse senedi fiyatlarını ve bir tahmin modeli tarafından elde edilen tahmin edilen hisse senedi fiyatlarını karşılaştıran bir çizgi grafiği

RECURRENT NEURAL NETWORK (RNN) MODEL

Tamamlayıcı bir yaklaşım olarak, hisse senedi fiyat tahmini için standart bir Tekrarlayan Sinir Ağı (RNN) da kullanıldı. Rnn'ler sıralı verileri işlemek üzere tasarlanmıştır

ve zamansal bağımlılıkları yakalamada etkinlik göstermiştir. RNN modeli, LSTM ve doğrusal regresyon modelleriyle aynı veri kümesi üzerinde eğitildi.

Modelin performansı, diğer modellerle aynı metrik kümesi kullanılarak değerlendirildi. rnn'nin sonuçlarının önceki modellerinkilerle karşılaştırılması, farklı sinir ağı mimarilerinin hisse senedi fiyatı tahmini bağlamında nasıl performans gösterdiğine dair içgörüler sağladı.




Fig6: RNN Model Tahmin çizim grafiği

V. RESULTS AND DISCUSSION

Farklı modellerin performansı çeşitli metriklerle göre değerlendirildi. Doğrusal regresyon modeli, hisse senedi fiyatlarının anlık özelliklerinden yararlanarak iyi bir temel tahmin sağlamıştır. LSTM modeli, verilerdeki daha uzun vadeli bağımlılıkları yakalayarak gelişmiş tahmin yetenekleri sergiledi ve bu da yönetim kurulunda iyileştirilmiş doğruluk ölçümleriyle sonuçlandı. RNN modelinin performansı, doğrusal regresyon modeli ile lstm'nin performansı arasına düştü ve sıralı bilgiyi dikkate almanın faydalarını sergiledi.

Bu sonuçlar, belirli görevler için uygun modelleme tekniklerinin seçilmesinin önemini vurgulamaktadır. Zamansal ilişkileri yakalama yeteneklerinden yararlanan LSTM ve RNN modelleri, hisse senedi fiyat verileri içindeki nüanslı kalıpları yakalamada doğrusal regresyon modelinden daha iyi performans gösterdi.

Bu çalışmada, Netflix hisse senedi fiyatlarının kapsamlı bir analizini, veri ön işleme, keşif amaçlı veri görselleştirme, istatistiksel analiz, doğrusal regresyon ve gelişmiş sinir ağı modelleri dahil olmak üzere bir dizi teknik kullanarak gerçekleştirdik. Geleneksel istatistiksel yaklaşımların ve modern makine öğrenimi yöntemlerinin birleşimi, tarihsel eğilimler hakkında fikir edinmemizi ve gelecekteki hisse senedi fiyatlarını tahmin etmemizi sağladı.

Sonuçlar, LSTM modelinin karmaşık zamansal kalıpları yakalamadaki etkinliğini vurgulayarak, hem doğrusal regresyon hem de RNN modellerine göre üstünlüğünü

gösterdi. Bu araştırma, hisse senedi fiyat analizi ve tahmini için hem klasik istatistiksel tekniklerden hem de son teknoloji makine öğrenimi algoritmalarından yararlanma potansiyelinin altını çizmektedir.

Gelecekteki Çalışmalar

Bu çalışma Netflix hisse senedi fiyatlarının bütünsel bir analizini sunarken, daha fazla araştırma için çok sayıda yol var. Gelecekteki çalışmalar, birden fazla modelin güçlü yönlerini birleştiren topluluk yöntemlerini keşfetmeyi, daha doğru tahminler için ekonomik göstergeler ve haber duyarlılığı gibi dış faktörleri dahil etmeyi ve daha da iyi sonuçlar elde etmek için daha karmaşık sinir ağı mimarilerini denemeyi içerebilir.

REFERENCES

- [1] VanderPlas, J. T. (2016). Python data science handbook. O'Reilly Media, Inc.
- [2] McKinney, W. (2012). Python for data analysis. O'Reilly Media, Inc.
- [3] Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT Press.
- [4] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. Neural computation, 9(8), 1735-1780.
- [5] Lipton, Z. C., Berkowitz, J., & Elkan, C. (2015). A critical review of recurrent neural networks for sequence learning. arXiv preprint arXiv:1506.00019.